



# PROYECTO FINAL BIG DATA APLICADO

Iker Muiños Morillo



# Introducción




## Preguntas:

- ¿En qué meses se publican más juegos?
- ¿Cómo ha evolucionado el precio medio de los juegos a lo largo de los años?
- ¿En qué continentes se publican más juegos?
- ¿Qué tipo de developer desarrolla más juegos?
- ¿Qué plataforma tiene mayor cuota de mercado y cómo se relaciona con el número de juegos?


# FUENTES DE DATOS

- Mezcla de datos reales e inventados
- El origen es Steam Games Dataset, sacado de Kaggle
- Distribuido entre 5 .csv
- games\_clean.csv (9989 filas de datos reales)
- developers.csv (9390 filas, inventado)
- platform.csv (5 filas, inventado)
- publishers.csv (7939 filas, inventado)
- game\_platforms.csv (17974 filas, inventado)
- Entre todos los .csv hay 61 variables de base




- developers.csv
- game\_platforms.csv
- games\_clean.csv
- platform.csv
- publishers.csv

# ESQUEMA CONCEPTUAL




# ESQUEMA LÓGICO




# INFRAESTRUCTURA UTILIZADA

- Una sola MV de Ubuntu 25.10
- 12 GB Ram, Procesador de 6 Núcleos
- 1 Único nodo (NameNode y DataNode en el mismo nodo)
- Hive como base de datos
- Airflow para ejecutar el ETL
- Superset para visualizar las consultas

# PROCESO ETL




# CONSULTA 1 - ¿EN QUÉ MESES SE PUBLICAN MÁS JUEGOS?







# CONSULTA 2 - EVOLUCIÓN DEL PRECIO MEDIO A LO LARGO DE LOS AÑOS



# CONSULTA 3 - CONTINENTES EN LOS QUE SE PUBLICAN MÁS JUEGOS




# CONSULTA 4 - ¿QUÉ TIPO DE DEVELOPER DESARROLLA MÁS JUEGOS?



# CONSULTA 5 - ¿QUÉ PLATAFORMA TIENE MAYOR CUOTA DE MERCADO Y CÓMO SE RELACIONA CON EL NÚMERO DE JUEGOS?

Consulta 5



# DIFICULTADES Y CURIOSIDADES

- Problemas de memoria con HDFS
- Me quedé sin espacio varias veces
- Superset fallaba a la hora de coger algunas consultas

# PRUEBA EN VIVO